

CNPEM
Centro Nacional de Pesquisa
em Energia e Materiais

**relatório final**
**período: 01/09/2025 a 30/09/2026**

**Projeto** Análise Comparativa de Desempenho de Ferramentas Computacionais para Perfilamento Automático de Metabólitos em Espectros de RMN $^{1}H$

**Bolsista PIBIC:** Tiago Alves Rodrigues

**Universidade:** PUC Campinas

**Orientador:** Dr. José Geraldo de Carvalho Pereira

**Unidade CNPEM:** LNBio

**Local e Data:** Campinas, 30 de Agosto de 2026

# Índice

1 Resumo ..... 4
2 Introdução ..... 4
3 Materiais e Métodos ..... 7
4 Resultados e Discussão ..... 12
5 Referências Bibliográficas ..... 19
6 Agradecimentos ..... 20

# 1 Resumo

A espectroscopia de ressonância magnética nuclear de próton (RMN $^{1}H$) consolidou-se como uma das plataformas mais robustas para estudos metabolômicos devido ao seu caráter não destrutivo, alta reprodutibilidade e capacidade de quantificação absoluta (Cobra, 2016; Rout et al., 2023). Contudo, a etapa de perfilamento de metabólitos permanece sendo o principal gargalo do fluxo de trabalho analítico (Flores et al., 2025). O método convencional ainda depende fortemente de espectroscopistas especialistas para o ajuste e análise manual de espectros, um processo que pode levar de 30 a 60 minutos por espectro (Lee et al., 2023) e cuja subjetividade inerente compromete a reprodutibilidade entre laboratórios (Hao et al., 2012; Tardivel et al., 2017). Diante dessa limitação, este trabalho realiza uma avaliação estatística, crítica e comparativa de ferramentas de perfilamento automatizado e semiautomatizado, utilizando como “padrão ouro” de validação o perfilamento manual por especialista assistido pelo software Chenomx NMR Suite (Chenomx Inc., 2025; Wang et al., 2022).

Para esse benchmarking foram avaliados 317 espectros reais de matrizes biológicas distintas, destes, 180 espectros de urina, adquiridos com equipamentos Bruker de 600 MHz e 137 espectros de soro, adquiridos com equipamentos Agilent/Varian de 500 MHz. Os dados foram integrados a um pipeline próprio para padronização de cálculo de métricas de detectabilidade e de acurácia quantitativa, frente ao padrão ouro. Das seis ferramentas inicialmente selecionadas, três puderam ser avaliadas quantitativamente, sendo essas ASICS (Tardivel et al., 2017), MagMet (Rout et al., 2023), e nmRanalysis (Flores et al., 2025). As demais foram excluídas do escopo por restrições de arquitetura, problemas de funcionamento ou não atendimento ao escopo do estudo.

Os resultados obtidos revelam que as plataformas e seus algoritmos ainda não estão prontos para superar os especialistas e suas análises manuais. Em grande parte das ferramentas, a interpretação de suas estatísticas revelou limitações severas das soluções. Nesses, o erro médio (MAPE) ficou bem acima de 100%. Portanto, esse panorama corrobora a literatura de validação de RMN (Wang et al., 2022), evidenciando que as ferramentas automáticas atuais ainda não estão maduras o suficiente para substituir a supervisão e o refinamento manual de um especialista. Outrossim, aponta que barreiras instrumentais como a compatibilidade de formatos brutos de diferentes fabricantes representam desafios tão críticos para a automação quanto a precisão dos algoritmos (Chenomx Inc., 2025; Rout et al., 2023).

# 2 Introdução

A metabolômica consolidou-se como uma das principais áreas para a compreensão de sistemas biológicos através da análise sistemática de metabólitos (Cobra, 2016). Dentre as principais técnicas utilizadas para a análise de metabólitos, temos a espectrometria de massa, e a espectroscopia de ressonância magnética nuclear (RMN), a que será abordada nesse trabalho. A espectroscopia de RMN destaca-se por ser uma técnica não destrutiva, com mínima preparação de amostras, altamente reprodutível e que permite a quantificação absoluta de compostos (Cobra, 2016; Lee et al., 2023). Contudo, embora a aquisição de dados espectrais seja amplamente automatizada, o processamento posterior, como o perfilamento de amostras e sua análise, é um gargalo no fluxo de trabalho, dependendo altamente de espectroscopistas especialistas para realizar análises confiáveis. O método tradicional de análise de espectros de RMN depende de profissionais altamente qualificados, sendo esse, um processo laborioso, que pode consumir de 30 a 60 minutos por espectro (Lee et al., 2023). Além da baixa produtividade e throughput, o perfilamento manual fica sujeito à subjetividade do especialista e à fadiga humana, o que acaba comprometendo a reprodutibilidade entre diferentes laboratórios (Hao et al., 2012; Wang et al., 2023). A complexidade intrínseca dos espectros de RMN $^{1}H$ é caracterizada pela sobreposição de picos, sensibilidade a artefatos como frequência, pH, temperatura, o que agrava o desafio (Flores et al., 2025). Para mitigar essas limitações, o campo desenvolveu diferentes abordagens, algumas ferramentas optaram por métodos estatísticos clássicos e modelos bayesianos (Hao et al., 2012; Lee et al., 2023), outras optaram por algoritmos de regressão linear com penalidades (Tardivel et al., 2017), e mais recentemente observou-se a introdução de Arquiteturas de Deep Learning, como redes neurais convolucionais e transformers (Johnson; Tipirneni-Sajja, 2025; Zhou et al., 2025). Apesar do avanço tecnológico, a eficácia e robustez dessas ferramentas automatizadas ainda demandam uma avaliação rigorosa frente ao atual padrão ouro, sendo este, a análise manual assistida por softwares de processamento de espectros, como Chenomx NMR Suite, MestRenova, TopSpin e outros

(BioSpin, 2021; Chenomx Inc., 2025; Mestrelab Research S.L.U., 2026). Nesse contexto, esse estudo realiza uma avaliação estatística, crítica e comparativa de ferramentas. O objetivo central é mensurar a precisão quantitativa e usabilidade desses programas em comparação com o perfilamento manual de um especialista, nosso padrão ouro.

## 2.1 Glossário

Para acompanhar e contextualizar as discussões metodológicas e de resultados apresentadas a seguir, descrevem-se nessa seção os conceitos mais relevantes sobre RMN utilizados no decorrer do estudo, desde o funcionamento do espectrômetro até as etapas de pré-processamento dos espectros.

### 2.1.1 Funcionamento de um Espectrômetro

Um espectrômetro é o equipamento que faz a aquisição de espectros de RMN, neste é colocada uma amostra de um biofluido, como urina ou soro, utilizados nesse estudo, ou outros biofluidos e amostras de células, tecidos e extratos de plantas. O espectrômetro é composto por 3 principais componentes, sendo esses o magneto, o emissor de radiofrequência (RF) e o receptor (BioSpin, 2021; Jiang, 2024; Rout et al., 2023).

#### 2.1.1.1 Magneto

O magneto é o componente que fornece o campo magnético estável $B_0$ (Jiang, 2024). Sob a influência desse campo, os spins dos núcleos com momento angular, como $^{1}H$, $^{13}C$ e $^{31}P$ alinham-se paralelamente em relação ao campo magnético $B_0$ (Rout et al., 2023).

#### 2.1.1.2 Emissor de RF

O emissor de radiofrequência (RF) é responsável por gerar pulsos curtos e rápidos de radiação eletromagnética que perturbam o alinhamento dos spins nucleares (Jiang, 2024). Ao receber essa energia do pulso de radiofrequência, os núcleos excitam-se e são deslocados de seu alinhamento com o campo magnético $B_0$. Um fator físico crítico decorrente do emissor é que a aquisição do sinal pelo aparelho não consegue começar exatamente no instante 0, pois os spins já iniciam a precessão durante o próprio pulso de radiofrequência (BioSpin, 2021). Esse atraso instrumental inevitável é o que gera as distorções de fase de primeira ordem, que distorcem a linha de base e a forma dos picos no espectro final.

#### 2.1.1.3 Receptor

O receptor registra a resposta de relaxação e induz a corrente que dá origem ao sinal espectral bruto (Jiang, 2024). Uma vez desligado o emissor de RF, os núcleos retornam gradualmente ao equilíbrio térmico por meio da relaxação, liberando a energia absorvida. Essa gera correntes elétricas oscilantes na bobina do receptor. Esse sinal decrescente no tempo é chamado de Decaimento Livre da Indução (Free Induction Decay, FID) (Jiang, 2024). O receptor amplifica e digitaliza o FID para que ele possa ser processado e analisado (Jiang, 2024; Rout et al., 2023).

#### 2.1.1.4 Frequência do Campo Magnético

Essa unidade mede a frequência de operação do espectrômetro. Magnetos de maior frequência aumentam drasticamente a relação sinal-ruído e a dispersão do deslocamento químico (Rout et al., 2023). Campos mais altos simplificam os espectros ao transformar acoplamentos fortes em acoplamentos fracos de primeira ordem, facilitando a identificação enquanto equipamentos de baixa frequência podem gerar espectros mais complexos, com acoplamentos fortes e sobreposição de picos (Johnson; Tipirneni-Sajja, 2024).

### 2.1.2 Parâmetros Relevantes

Existem alguns parâmetros relevantes que influenciam diretamente na aquisição e interpretação de espectros de RMN $^{1}$H.

#### 2.1.2.1 Deslocamento Químico ($\delta$)

O deslocamento químico de cada ressonância é dependente do campo magnético local experimentado por cada núcleo, o qual é determinado pelo grau em que os orbitais moleculares (ambiente eletrônico) blindam a influência do campo magnético externo do espectrômetro (Muncey et al., 2010). O deslocamento químico

é expresso na unidade de partes por milhão (ppm) em relação a uma referência como TSP ou DSS, reflete diretamente a estrutura química ou o ambiente eletrônico do composto (Jiang, 2024).

#### 2.1.2.2 Acoplamento Spin-Spin ($J$)

Resulta da interação entre spins de núcleos vizinhos, causando desdobramento dos sinais em múltiplos picos ao decorrer do espectro (Muncey et al., 2010), revelando conectividade atômica.

#### 2.1.2.3 Intensidade do Sinal

A área integrada sob o pico é proporcional ao número de núcleos observados na amostra, permitindo a determinação da concentração dos metabólitos (Muncey et al., 2010). Em sistemas sem interações interferentes, as intensidades dos picos de RMN correlacionam-se linearmente com a concentração, possibilitando a quantificação absoluta ou relativa (Jiang, 2024).

#### 2.1.2.4 Área Sob a Curva

A área sob a curva, ou seja, a integral de um sinal em RMN $^1$H é diretamente proporcional à quantidade de prótons que geram aquele sinal (Muncey et al., 2010; Schmid; Ziebart; Others, 2025).

#### 2.1.2.5 Multiplicidade do Efeito Telhado (Rooftopping)

A multiplicidade é responsável pela divisão de um sinal em multipletos decorrente do acoplamento spin-spin. A multiplicidade segue a regra $n + 1$, a qual n é o número de hidrogênios vizinhos (Schmid; Ziebart; Others, 2025). Contudo, em sistemas fortemente acoplados, nos quais a diferença de deslocamento químico em Hz é próxima do valor da constante de acoplamento $J$, isso é, $\frac{\Delta\delta}{J} \leq 10$, ocorre o fenômeno de rooftopping (Schmid; Ziebart; Others, 2025). Esse distorce as intensidades teóricas das linhas dos multipletos, inclinando-as em direção ao multipleto de acoplamento, podendo gerar desafios na quantificação (Schmid; Ziebart; Others, 2025).

### 2.1.3 Pré-processamento de Espectros de RMN $^1$H

O sinal bruto adquirido pelo espectrômetro, denominado *Free Induction Decay* (FID), corresponde ao decaimento temporal da magnetização transversal dos núcleos de $^1$H. Sob a ação de um campo magnético estático intenso $B_0$, os momentos magnéticos nucleares dos átomos de hidrogênio se alinham ao campo, a aplicação de um pulso de radiofrequência perturba esse equilíbrio, e o retorno dos núcleos ao alinhamento com $B_0$ gera um sinal oscilatório decrescente no domínio do tempo, captado pelo receptor do equipamento. O FID, contudo, não é diretamente interpretável, sendo necessária uma série de etapas de pré-processamento para convertê-lo em um espectro analisável (Jiang, 2024). A seguir mostram-se as etapas de pré processamento.

#### 2.1.3.1 Apodização

A apodização consiste em multiplicar o FID por uma função de janela matemática, como uma gaussiana ou uma exponencial, antes da transformada de Fourier. Essa função força o sinal a decair suavemente até zero ao final do período de aquisição, reduzindo o truncamento abrupto do FID e os artefatos de oscilação (*ringing*, do tipo Gibbs) que esse truncamento geraria no espectro. O processo melhora a relação sinal-ruído e suaviza o decaimento do sinal, facilitando a identificação de picos, embora possa reduzir levemente a resolução espectral (Jiang, 2024).

#### 2.1.3.2 Zero Filling

*Zero filling* é o processo de adicionar zeros ao final do FID antes da transformada de Fourier. Embora não acrescente informação real ao sinal, esse procedimento aumenta o número de pontos interpolados no domínio da frequência, o que melhora a resolução digital do espectro, suaviza sua aparência e facilita a distinção entre picos próximos (Jiang, 2024).

#### 2.1.3.3 Transformada de Fourier

A transformada de Fourier converte o FID, originalmente representado no domínio do tempo, para o domínio da frequência, produzindo o espectro de RMN característico, no qual cada pico corresponde a um ou mais metabólitos presentes na amostra.

#### 2.1.3.4 Alinhamento da Referência (Calibração)

O alinhamento da referência consiste em ajustar o espectro em relação a um pico de referência de um composto com concentração e posição conhecidas, posicionando-o no zero do eixo de deslocamento químico (ppm). Essa calibração garante a consistência da posição dos demais picos e é essencial para comparar espectros de diferentes amostras, assegurando que picos em uma mesma posição correspondam ao mesmo metabólito.

#### 2.1.3.5 Correção de Fase

A correção de fase garante que os picos do espectro estejam em uma posição puramente absortiva, condição essencial para a identificação e quantificação correta dos metabólitos. Uma fase incorreta pode gerar picos invertidos ou distorcidos, comprometendo a interpretação do espectro.

#### 2.1.3.6 Correção de Linha de Base

A correção de linha de base uniformiza a base do espectro, evitando interferências na identificação de picos e padronizando o espectro para análises comparativas entre amostras.

#### 2.1.3.7 Remoção de Regiões Não Desejadas

Consiste em remover ou omitir do espectro regiões sem informação relevante para a análise, como o pico da água ou, em amostras de urina, o pico da ureia, que podem prejudicar a identificação e quantificação dos demais metabólitos.

#### 2.1.3.8 Remoção do Group Delay (Bruker)

Etapa exclusiva de equipamentos de um dos fabricantes (Bruker), que consiste em corrigir o atraso temporal introduzido por filtros digitais durante a aquisição, atraso este que pode comprometer a nitidez dos picos e a qualidade geral do espectro.

Embora essas etapas sejam bem estabelecidas do ponto de vista conceitual, sua automação completa permanece um desafio técnico relevante. Diversos algoritmos tentam automatizar a correção de fase, como ACME, MinNeg e métodos baseados em integral de área, porém sua confiabilidade ainda é limitada, podendo gerar resultados inconsistentes entre diferentes espectros (De Brouwer, 2009). De forma semelhante, algoritmos de correção de linha de base como ALS (*Asymmetric Least Squares*) e a suavização de Whittaker são amplamente utilizados e relativamente confiáveis, mas ainda apresentam dificuldades em espectros com alta sobreposição de picos ou baixa relação sinal-ruído.

Com esses conceitos bem estabelecidos, a seção a seguir descreve os materiais e métodos empregados nesse estudo, as amostras, critérios de seleção das ferramentas avaliadas, e o pipeline desenvolvido para viabilizar a comparação entre elas.

# 3 Materiais e Métodos

## 3.1 Obtenção e Caracterização das Amostras

Para conduzir este estudo, foi solicitado ao espectroscopista responsável pela aquisição, processamento e perfilamento de RMN $^{1}$H do LNBio um conjunto de espectros de urina e soro, por serem os tipos de amostra mais comuns em estudos de metabolômica e também os mais amplamente aceitos pelos diferentes softwares avaliados:

- Amostras de urina: coletadas em equipamento Bruker de 600 MHz, totalizando 180 espectros.
- Amostras de soro: coletadas em equipamento Agilent/Varian de 500 MHz, totalizando 137 espectros.

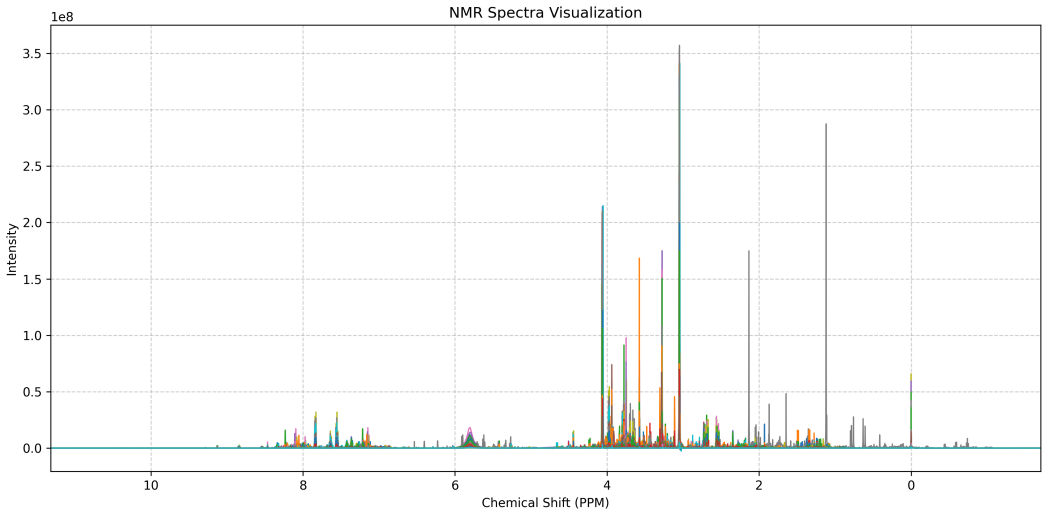



Figura 1: sobreposição dos 180 espectros de urina (Bruker, 600 MHz) utilizados no estudo.

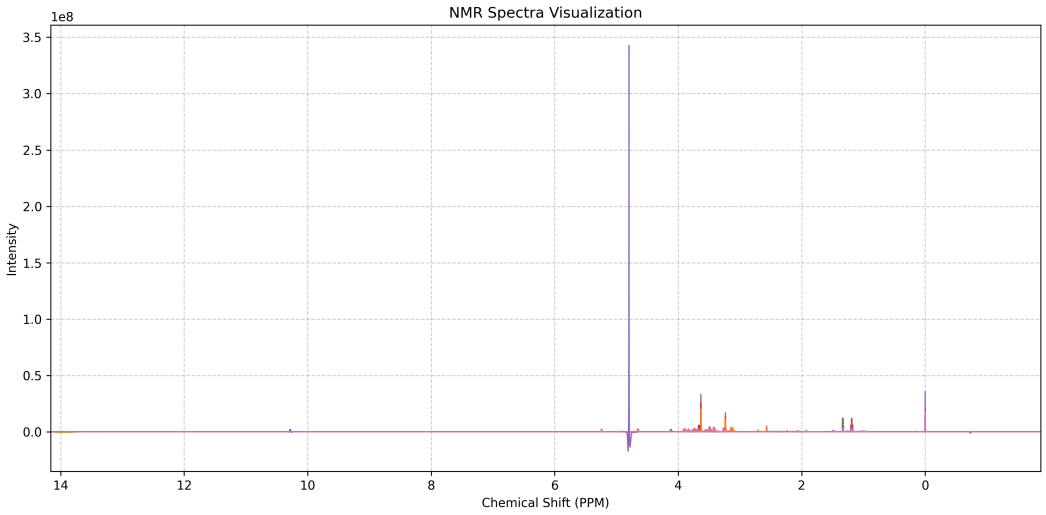



Figura 2: sobreposição dos 137 espectros de soro (Agilent/Varian, 500 MHz) utilizados no estudo. O pico de água não suprimido em torno de 4,7 ppm, presente em praticamente todas as amostras, ilustra o tipo de artefato instrumental que as etapas de pré-processamento (remoção de regiões não desejadas) precisam tratar.

A diversidade de fabricantes, frequências de operação e biofluidos teve como objetivo avaliar a robustez dos softwares frente a diferentes resoluções espectrais e artefatos instrumentais. Os 317 espectros foram inicialmente fornecidos em formato bruto, sem qualquer pré-processamento, de modo a validar a capacidade de automação das plataformas que alegam realizar essas etapas automaticamente. Posteriormente, para as plataformas que não realizavam o pré-processamento de forma automática, os mesmos 317 espectros foram novamente fornecidos, já pré-processados pelo especialista, de forma que o pré-processamento manual não constituísse uma etapa adicional de possível introdução de erro na avaliação dessas ferramentas.

Como padrão ouro para comparação, utilizou-se o perfilamento manual realizado pelo especialista por meio do software Chenomx (Chenomx Inc., 2025), referência na literatura para avaliação de acurácia quantitativa em metabolômica por RMN.

## 3.2 Seleção e Avaliação de Ferramentas Computacionais

A princípio, foram selecionadas seis ferramentas de perfilamento automático ou semiautomático de metabólitos para avaliação: ASICS (Lefort et al., 2019; Tardivel et al., 2017), MagMet (Lee et al., 2023; Rout et al., 2023), NMRQNet (Wang et al., 2023), nmrformer (Zhou et al., 2025), nmRanalysis (Flores et al., 2025)

e Bayesil (Ravanbakhsh et al., 2015). A seleção buscou contemplar diferentes abordagens metodológicas identificadas na literatura, incluindo métodos estatísticos clássicos e bayesianos, modelos de regressão linear penalizada e arquiteturas de aprendizado de máquina, permitindo comparar seu desempenho tanto entre si quanto em relação ao padrão ouro estabelecido pela análise manual.

## 3.3 Software Desenvolvido

Comparar ferramentas de perfilamento apresenta um desafio prático: cada uma produz resultados em um formato de arquivo diferente, com nomes de metabólitos escritos de forma distinta, e a comparação manual desses resultados, de centenas de espectros e metabólitos, seria inviável à mão.

Esse pipeline, desenvolvido em Python, é responsável por padronizar todo o processo de avaliação: preparar os dados de entrada no formato exigido por cada ferramenta, padronizar as saídas heterogêneas geradas por cada uma delas, armazená-las em um banco de dados relacional, comparar os resultados de cada ferramenta com o padrão ouro calculando as métricas estatísticas de desempenho, e gerar as visualizações gráficas usadas neste relatório, como os gráficos de Bland-Altman e as curvas de precisão-recall.

### 3.3.1 Padronização de Dados

Os resultados brutos de cada ferramenta (ASICS, MagMet, nmRanalysis) e do padrão ouro (Chenomx) chegam em formatos heterogêneos entre si: cabeçalhos diferentes, orientação inconsistente entre linhas e colunas e nomenclatura não padronizada de metabólitos. Essa heterogeneidade impede a comparação direta entre ferramentas. Para mitigar isso, o pipeline aplica três etapas encadeadas, sendo essas leitura, limpeza e formatação, com uma implementação específica para cada ferramenta, unificando tudo em um formato tabular comum (linhas = amostras, colunas = metabólitos).

A padronização de nomenclatura de metabólitos é feita a partir de um identificador canônico (HMDB) e de uma tabela de sinônimos, o que permite comparar resultados de ferramentas que nomeiam o mesmo metabólito de formas distintas.

### 3.3.2 Aplicação na Ferramenta

O pipeline é exposto ao usuário por meio de uma interface de linha de comando simples, com um comando para cada etapa do fluxo: padronizar os dados brutos, inseri-los no banco, calcular as métricas estatísticas e gerar os gráficos. Essa separação permite reexecutar qualquer etapa isoladamente, por exemplo, recalcular apenas as métricas de uma ferramenta específica, sem reingestão de dados, o que foi útil durante o desenvolvimento iterativo do projeto e facilita estender o pipeline para novos conjuntos de dados no futuro.

### 3.3.3 Alimentação de Dados

A inserção dos dados padronizados no banco segue uma ordem específica: primeiro as entidades de catálogo do experimento (instrumentos, ferramentas, espectros), depois os resultados de cada ferramenta e, por último, o padrão ouro, que depende dos experimentos já cadastrados. Falhas são tratadas espectro a espectro, de modo que um erro pontual não interrompa o processamento de todo o lote.

A lógica de consistência dos dados (resolução de sinônimos de metabólitos, atualização sem duplicação de registros) foi colocada no próprio banco, e não no código Python, para que qualquer forma futura de acesso aos dados, reutilize as mesmas regras.

### 3.3.4 Banco de Dados

Optou-se por um banco de dados pois dessa forma haveria um lugar único, organizado especificamente para guardar os dados pertinentes ao estudo sem a necessidade de refazer manualmente planilhas ou tabelas toda vez que uma nova comparação for necessária. Dessa forma, toda vez que alguém quiser comparar um número, esse estará normalizado e sempre com os mesmos critérios, logo o banco garante que a regra de comparação é sempre a mesma, para todas as ferramentas, e permite recalcular ou conferir qualquer resultado sem refazer o trabalho manual.

O banco de dados relacional foi implementado em PostgreSQL (hospedado via Supabase) para garantir integridade referencial entre as entidades do domínio (ferramentas, instrumentos, metabólitos, experimentos)

e para poder embutir parte das regras de consistência diretamente no banco, tornando-as independentes do cliente que as acessa.

O esquema é normalizado e organizado em três camadas conceituais: entidades de catálogo, tabelas com os resultados brutos de cada ferramenta e do padrão ouro, e tabelas de análise já calculadas — estas últimas nas três granularidades usadas na seção de Resultados (por espectro, por metabólito e por ferramenta). O versionamento do esquema é feito por migrações SQL, aplicadas de forma controlada e rastreável.

#### 3.3.4.1 Design do Banco de Dados

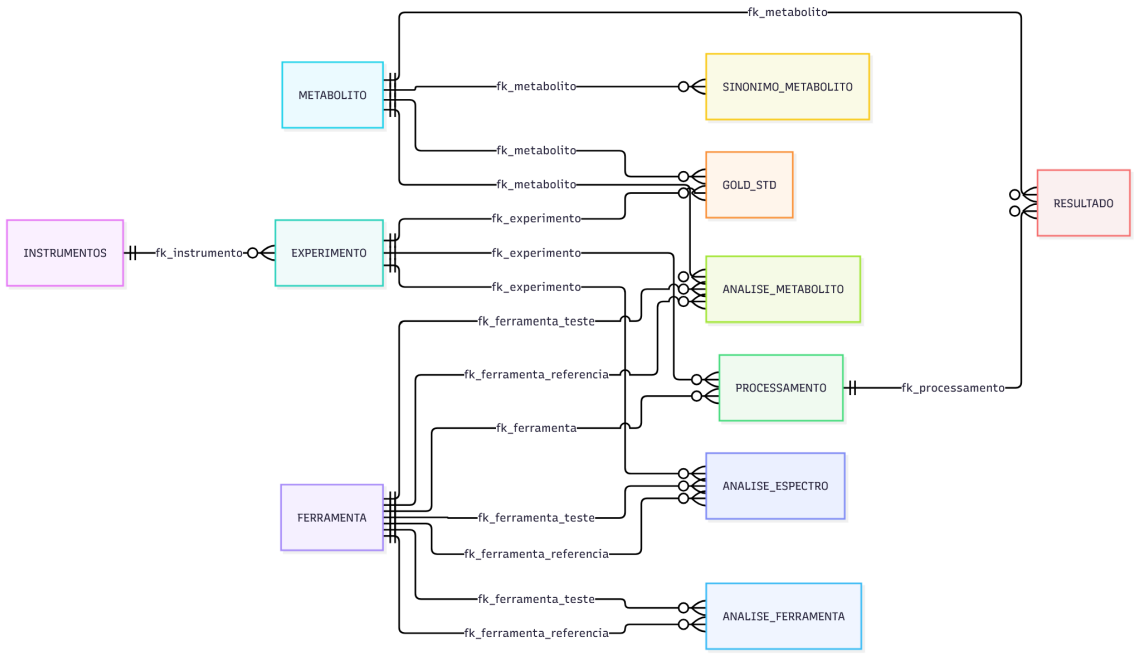



Figura 3: A figura explicita o diagrama entidade-relacionamento, o qual reflete a decisão central do modelo: as tabelas de análise possuem duas relações distintas com a tabela de ferramentas, uma para a ferramenta sendo testada, outra para a referência usada na comparação. Esse autorrelacionamento permite comparar qualquer ferramenta contra qualquer outra, incluindo o próprio Gold Standard, tratado como mais uma "ferramenta" no catálogo, sem a necessidade de uma tabela ou coluna dedicada exclusivamente à comparação com o padrão-ouro. O modelo na foto abstrai os atributos das entidades para melhor entendimento das relações, evitando poluição visual do diagrama

### 3.3.5 Análise Comparativa de Ferramentas

A comparação entre as ferramentas de perfilamento (ASICS, MagMet, nmRanalysis) e o Gold Standard é o objetivo estatístico central do projeto. Para cada par ferramenta-padrão ouro, o `StatsEngine` combina as concentrações reportadas pela ferramenta com as do padrão ouro e aplica, de forma independente, cada uma das métricas descritas na seção seguinte (correlação de Pearson, correlação de Spearman, MBE, MSE, MAPE, precisão e recall).

Essas métricas são calculadas em três granularidades, cada uma respondendo a uma pergunta distinta sobre o desempenho das ferramentas:

1. por espectro: avalia o perfil metabólico completo de uma amostra, medindo o quão bem a ferramenta reproduz, naquela amostra específica, o conjunto de metabólitos identificados pelo padrão ouro;
2. por metabólito: avalia o desempenho da ferramenta para um metabólito específico ao longo de todas as amostras analisadas, revelando se há metabólitos sistematicamente mal quantificados por uma ferramenta;
3. por ferramenta: avalia o desempenho global e agregado de cada ferramenta, permitindo compará-las diretamente entre si e frente ao padrão ouro.

### 3.3.6 Definição das Métricas

Para cada par ferramenta padrão ouro, seja $t_i$ a concentração reportada pela ferramenta testada e $g_i$ a concentração do padrão ouro (Chenomx) para a $i$-ésima observação metabólito-espectro, dentre $n$ observações pareadas (isto é, metabólitos identificados tanto pela ferramenta quanto pelo padrão ouro no mesmo espectro). As métricas de acurácia quantitativa e de detectabilidade calculadas pelo `StatsEngine`, apresentadas na seção de Resultados, são definidas a seguir.

#### 3.3.6.1 Correlação de Pearson ($r$)

Mede a força da associação linear entre os valores reportados pela ferramenta e o padrão ouro:

$$r = \frac{\sum_{i=1}^{n}(t_i - \bar{t})(g_i - \bar{g})}{\sqrt{\sum_{i=1}^{n}(t_i - \bar{t})^2 \cdot \sum_{i=1}^{n}(g_i - \bar{g})^2}}$$

#### 3.3.6.2 Correlação de Spearman ($\rho$)

Calculada da mesma forma que a correlação de Pearson, porém aplicada sobre os postos (*ranks*) dos valores, e não sobre os valores brutos. Por depender apenas da ordenação relativa dos pares, é uma medida de associação monotônica, mais robusta a outliers do que a correlação de Pearson.

#### 3.3.6.3 Viés Médio (MBE)

Quantifica o erro sistemático médio entre ferramenta e padrão ouro, preservando o sinal da diferença:

$$\mathrm{MBE} = \frac{1}{n}\sum_{i=1}^{n}(t_i - g_i)$$

Valores positivos indicam que a ferramenta superestima, em média, a concentração do padrão ouro, valores negativos indicam subestimação.

#### 3.3.6.4 Erro Quadrático Médio (MSE)

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(t_i - g_i)^2$$

#### 3.3.6.5 Erro Percentual Absoluto Médio (MAPE)

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\frac{|t_i - g_i|}{g_i} \times 100\%$$

Pares em que $g_i = 0$ são ignorados no cálculo, pois o erro percentual não é definido para essa divisão.

#### 3.3.6.6 Razão Reportado/GS

Relação entre o total de metabólitos reportados pela ferramenta e o total de metabólitos do padrão ouro em um espectro, sem exigir que sejam os mesmos metabólitos entre os dois conjuntos:

$$\text{Razão Reportado/GS} = \frac{N_{\text{tool}}}{N_{\text{gs}}} \times 100\%$$

em que $N_{\text{tool}}$ é o número total de metabólitos reportados pela ferramenta e $N_{\text{gs}}$ é o número total de metabólitos do padrão ouro.

#### 3.3.6.7 Precisão

Proporção dos metabólitos reportados pela ferramenta que de fato correspondem a um metabólito do padrão ouro:

$$\text{Precisão} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}} = \frac{N_{\text{match}}}{N_{\text{tool}}}$$

#### 3.3.6.8 Recall

Proporção dos metabólitos do padrão ouro que a ferramenta conseguiu identificar corretamente:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{N_{\text{match}}}{N_{\text{gs}}}$$

em que $N_{\text{match}}$ é o número de metabólitos identificados tanto pela ferramenta quanto pelo padrão ouro no mesmo espectro (verdadeiros positivos).

Software desenvolvido e utilizado nesse trabalho está disponível em: *https://github.com/tiago-rods/NMR-data-analysis.git*

# 4 Resultados e Discussão

A avaliação comparativa segue diretamente o desenho metodológico apresentado na seção anterior: os 317 espectros (180 de urina, adquiridos em equipamento Bruker de 600 MHz, e 137 de soro, adquiridos em equipamento Agilent/Varian de 500 MHz) foram submetidos às seis ferramentas selecionadas, ASICS, MagMet, NMRQNet, nmrformer, nmRanalysis e Bayesil. Dessas, apenas três (ASICS, em seus dois modos de entrada, MagMet e nmRanalysis) completaram o perfilamento e produziram resultados comparáveis ao padrão ouro; NMRQNet, nmrformer e Bayesil não puderam ser avaliadas quantitativamente pelos motivos detalhados na seção de Discussão, adiante. Os resultados das três ferramentas quantificáveis, padronizados e armazenados pelo pipeline descrito em Materiais e Métodos, foram comparados ao perfilamento manual do especialista via Chenomx, adotado como padrão ouro.

## 4.1 Resultados da Análise Comparativa de Ferramentas

Como apresentado na subseção Análise Comparativa de Ferramentas, as métricas estatísticas calculadas pelo motor de comparações estatísticas (correlação de Pearson, correlação de Spearman, MBE, MSE, MAPE, precisão e recall) são persistidas em três granularidades distintas, cada uma respondendo a uma pergunta diferente sobre o desempenho das ferramentas. Os resultados desta seção estão organizados de acordo com esses três níveis. As causas qualitativas por trás desses números — a arquitetura de cada ferramenta, o formato de entrada aceito, o modo de operação (automático ou direcionado) e os motivos pelos quais três das seis ferramentas não puderam ser avaliadas quantitativamente — são discutidas individualmente na seção de Discussão, a seguir.

### 4.1.1 Análise por Ferramenta

No nível mais agregado, a análise por ferramenta (`analise_ferramenta`) resume o desempenho global de cada software em um único conjunto de métricas, calculado sobre a totalidade dos espectros e metabólitos avaliados. É esse nível que permite comparar diretamente as seis ferramentas entre si e responder à pergunta central do projeto: qual delas mais se aproxima do padrão ouro estabelecido pelo especialista. Das seis ferramentas selecionadas, apenas ASICS (nos dois modos de entrada, *fid* e *csv*), MagMet e nmRanalysis produziram resultados quantificáveis frente ao padrão ouro; NMRQNet, nmrformer e Bayesil não puderam ser avaliadas (ver Discussão, a seguir).

| Ferramenta | N obs. | Razão Reportado/GS (%) | Precisão | Recall |
|---|---|---|---|---|
| ASICS (fid) | 2877 | 55,3 | 0,62 | 0,27 |
| ASICS (csv) | 11600 | 165,3 | 0,38 | 0,62 |
| MagMet | 1153 | 22,5 | 0,80 | 0,18 |
| nmRanalysis | 12861 | 76,0 | 0,90 | 0,68 |

Tabela 1: métricas de detectabilidade por ferramenta, agregadas sobre todos os espectros e metabólitos (`analise_ferramenta`). A coluna “Razão Reportado/GS (%)” representa a razão entre o total de metabólitos reportados pela ferramenta e o total de metabólitos do padrão ouro naquele espectro, sem exigir que sejam os mesmos metabólitos, por isso pode ultrapassar 100% quando a ferramenta reporta mais metabólitos do que os presentes no padrão ouro.

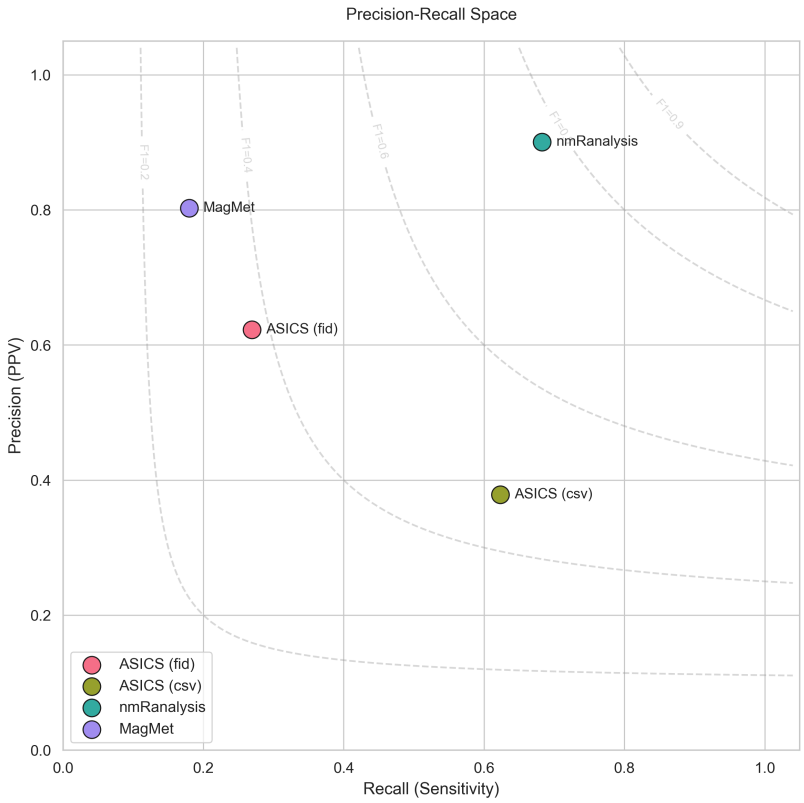



Figura 4: precisão versus recall por ferramenta, com curvas de isovalor de F1-score sobrepostas — visualização complementar à Tabela 1.

| Ferramenta | Pearson r | Spearman r | MBE | MSE | MAPE (%) |
|---|---|---|---|---|---|
| ASICS (fid) | 0,81 | 0,51 | 565,2 | $4{,}99 \times 10^{6}$ | 1260,9 |
| ASICS (csv) | 0,80 | 0,70 | 2163,5 | $2{,}74 \times 10^{8}$ | 884,0 |
| MagMet | 0,06 | 0,39 | 166,6 | $4{,}02 \times 10^{5}$ | 1757,0 |
| nmRanalysis | 0,08 | 0,27 | 2864,4 | $1{,}60 \times 10^{8}$ | 11186,4 |

Tabela 2: métricas de acurácia quantitativa por ferramenta (`analise_ferramenta`). Todos os valores de Pearson r são estatisticamente significativos ($p < 0{,}05$); o de MagMet é o mais marginal ($p = 0{,}049$), praticamente no limiar de significância.

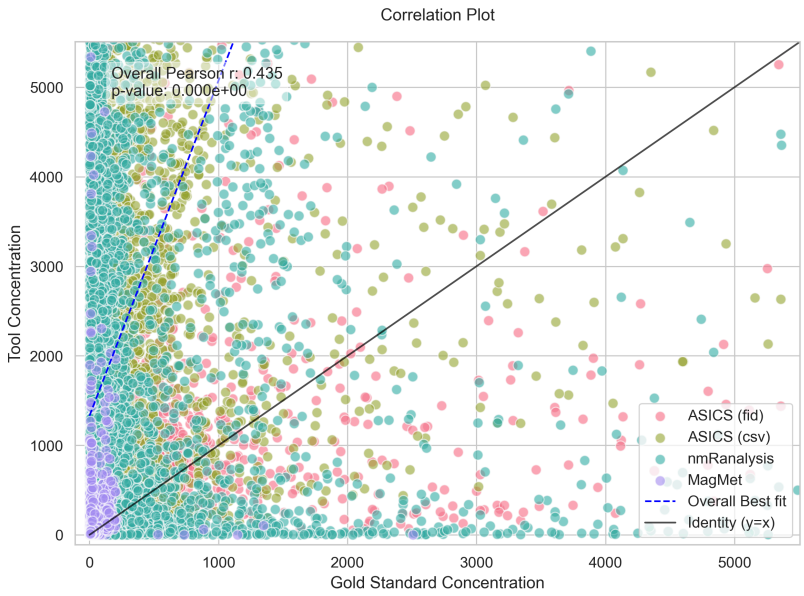


Figura 5: concentração estimada por cada ferramenta versus concentração do padrão ouro, por observação metabólito-espectro, colorida por ferramenta. A linha identidade (y=x) representa a concordância perfeita; a linha tracejada é o ajuste linear considerando todas as ferramentas conjuntamente (Pearson r = 0,435).

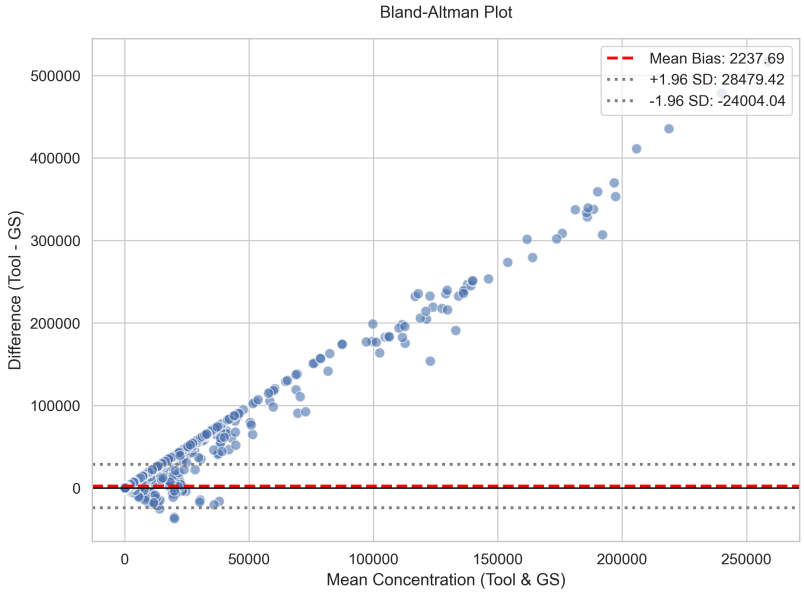



Figura 6: gráfico de Bland-Altman (diferença Ferramenta Padrão Ouro versus a média dos dois), agregando as ferramentas quantificáveis. O MBE positivo e a dispersão crescente com a concentração média ilustram o padrão de erro sistemático de escala já indicado na Tabela 2.

Um primeiro padrão emerge dessas duas tabelas: correlação (Pearson/Spearman) e erro percentual médio (MAPE) não caminham juntos. ASICS, nos dois modos, é a ferramenta com maior correlação linear com o padrão ouro, mas também apresenta MBE e MSE elevados quando operando em modo csv — indicando que, apesar de acompanhar a tendência geral das concentrações, a ferramenta erra sistematicamente na escala absoluta dos valores. nmRanalysis apresenta a melhor detectabilidade (maior recall, maior precisão), mas a pior acurácia quantitativa de todas, com Pearson r próximo de zero e MAPE superior a 11000%. MagMet, por sua vez, é a ferramenta mais conservadora: alta precisão (0,80) combinada com o menor recall (0,18), isto é, quando identifica um metabólito raramente erra o alvo, mas identifica poucos. As razões específicas por trás desses perfis distintos são discutidas individualmente, ferramenta a ferramenta, na seção de Discussão.

### 4.1.2 Análise por Espectro

No nível intermediário, a análise por espectro (`analise_espectro`) avalia o desempenho de cada ferramenta amostra a amostra, considerando o perfil metabólico completo identificado em cada espectro individual. É esse nível que permite investigar se o desempenho de uma ferramenta é consistente entre amostras ou se varia conforme características do espectro, como o biofluido de origem (soro ou urina), o fabricante do equipamento ou a relação sinal-ruído. Como o número de espectros (317) inviabiliza uma tabela linha a linha, os resultados desse nível são agregados por ferramenta e biofluido.

| Ferramenta | Biofluido | N espectros | Pearson r | MBE | MAPE (%) | Precisão | Recall |
|---|---|---|---|---|---|---|---|
| ASICS (fid) | Urina | 152 | 0,78 | −155,6 | 1112,7 | 0,62 | 0,27 |
| ASICS (csv) | Soro | 137 | 0,98 | 631,5 | 1048,7 | 0,37 | 0,70 |
| ASICS (csv) | Urina | 179 | 0,97 | 3179,1 | 791,5 | 0,38 | 0,57 |
| MagMet | Soro | 136 | 0,65 | 178,2 | 1747,0 | 0,80 | 0,18 |
| nmRanalysis | Soro | 137 | 0,20 | 2284,2 | 22576,4 | 0,87 | 0,71 |
| nmRanalysis | Urina | 179 | 0,01 | 3157,6 | 4882,5 | 0,92 | 0,66 |

Tabela 3: métricas médias calculadas por espectro (`analise_espectro`) e agregadas por ferramenta e biofluido. Diferente das Tabelas 1 e 2, que agregam todas as observações metabólito-espectro em uma única correlação (pooled), aqui cada valor de Pearson r é primeiro calculado dentro de um único espectro e depois tirado a média entre espectros do mesmo grupo. Para os espectros de urina, tanto o modo *fid* quanto o modo *csv* do ASICS processaram as amostras com sucesso (152 e 179 dos 180 espectros, respectivamente) e por isso são mantidos como linhas separadas, na mesma convenção das Tabelas 1 e 2; MagMet não possui linha de Urina por não processar espectros Bruker (ver Discussão).

### 4.1.3 Análise por Metabólito

No nível mais granular, a análise por metabólito (`analise_metabolito`) avalia o desempenho de cada ferramenta para um metabólito específico, agregado ao longo de todas as amostras em que esse metabólito foi identificado. É esse nível que permite identificar padrões sistemáticos, como classes de metabólitos que uma ferramenta tende a super- ou subestimar, ou metabólitos que nenhuma das ferramentas consegue quantificar de forma confiável. Por conta do grande número de metabólitos avaliados (de 33 a 59, a depender da ferramenta), o corpo do texto apresenta apenas os cinco metabólitos com menor e os cinco com maior MAPE por ferramenta.

| ASICS (fid) | MAPE (%) | Pearson r | N obs. |
|---|---|---|---|
| **Melhores** | | | |
| *L-Histidine* | 67,8 | 0,48 | 74 |
| *Dimethylamine* | 111,0 | 0,41 | 110 |
| *Taurine* | 114,2 | 0,22 | 87 |
| *D-Glucose* | 132,6 | 0,48 | 42 |
| *Creatinine* | 133,7 | 0,62 | 149 |
| **Piores** | | | |
| *L-Isoleucine* | 1682,7 | 0,28 | 71 |
| *Hypoxanthine* | 1719,3 | −0,53 | 12 |
| *Glycerophosphocholine* | 6080,0 | 0,11 | 44 |
| *Uracil* | 8919,8 | 0,16 | 117 |
| *Uridine* | 13746,0 | −0,38 | 77 |

Tabela 4: metabólitos com menor e maior MAPE — ASICS, modo fid (`analise_metabolito`).

| ASICS (csv) | MAPE (%) | Pearson r | N obs. |
|---|---|---|---|
| **Melhores** | | | |
| *Inosine* | 86,5 | 0,23 | 32 |
| *Butyric acid* | 112,3 | 0,53 | 46 |
| *L-Histidine* | 188,4 | 0,48 | 200 |
| *Malonic acid* | 276,1 | 0,57 | 152 |
| *Hypoxanthine* | 295,8 | 0,43 | 244 |
| **Piores** | | | |
| *L-Proline* | 1816,7 | 0,11 | 135 |
| *L-Carnitine* | 1982,9 | 0,56 | 286 |
| *Succinic acid* | 2012,7 | 0,84 | 184 |
| *beta-Alanine* | 2140,3 | 0,73 | 179 |
| *Glycerophosphocholine* | 2418,2 | 0,54 | 150 |

Tabela 5: metabólitos com menor e maior MAPE — ASICS, modo csv (`analise_metabolito`). Nota-se que, entre os piores casos, *Succinic acid* e *beta-Alanine* têm Pearson r alto (0,84 e 0,73) apesar do MAPE elevado — um sinal claro de erro sistemático de escala (MBE/offset) e não de ruído aleatório, coerente com o padrão já observado na Tabela 2.

| MagMet | MAPE (%) | Pearson r | N obs. |
|---|---|---|---|
| **Melhores** | | | |
| *Creatinine* | 44,0 | 0,78 | 3 |
| *Methanol* | 55,6 | 0,00 | 1 |
| *L-Lysine* | 72,1 | 0,00 | 1 |
| *L-Isoleucine* | 79,6 | −0,96 | 3 |
| *L-Leucine* | 90,8 | −0,90 | 3 |
| **Piores** | | | |
| *L-Tyrosine* | 3019,7 | 0,00 | 2 |
| *L-Proline* | 5626,4 | −0,64 | 7 |
| *L-Aspartic acid* | 6790,2 | −0,13 | 126 |
| *L-Carnitine* | 16782,8 | −0,32 | 16 |
| *Acetoacetic acid* | 33173,1 | −0,08 | 8 |

Tabela 6: metabólitos com menor e maior MAPE — MagMet (`analise_metabolito`). Os “melhores” resultados devem ser lidos com cautela: quase todos têm de 1 a 3 observações, o que torna a métrica pouco confiável estatisticamente. O único caso com amostragem robusta (N=126), *L-Aspartic acid*, está entre os piores (MAPE de 6790%), o que é mais representativo do desempenho real da ferramenta do que os casos de baixo N.

| nmRanalysis | MAPE (%) | Pearson r | N obs. |
|---|---|---|---|
| **Melhores** | | | |
| *Dimethylamine* | 74,4 | 0,66 | 174 |
| *cis-Aconitic acid* | 100,9 | 0,49 | 176 |
| *Hippuric acid* | 123,7 | 0,39 | 179 |
| *Glycolic acid* | 137,2 | 0,59 | 92 |
| *Formic acid* | 142,5 | 0,39 | 283 |
| **Piores** | | | |
| *L-Carnitine* | 32704,8 | 0,03 | 313 |
| *L-Phenylalanine* | 41609,4 | 0,01 | 137 |
| *Urocanic acid* | 43175,6 | 0,25 | 113 |
| *Choline* | 73426,6 | 0,02 | 137 |
| *Dimethylglycine* | 165781,9 | 0,29 | 316 |

Tabela 7: metabólitos com menor e maior MAPE — nmRanalysis (`analise_metabolito`). Mesmo entre os “melhores” casos, a correlação de Pearson raramente ultrapassa 0,6, reforçando que a boa detectabilidade dessa ferramenta (Tabela 1) não se traduz em quantificação confiável.

Dentro de cada um desses três níveis, as métricas se dividem ainda em duas categorias conceituais que não devem ser misturadas em uma mesma tabela: métricas de *detectabilidade* (razão reportado/GS, precisão, recall), que respondem se a ferramenta encontrou o metabólito certo; e métricas de *acurácia quantitativa* (correlação de Pearson, correlação de Spearman, MBE, MSE, MAPE), que respondem se, uma vez encontrado, o metabólito foi quantificado corretamente. Por tratarem de perguntas conceitualmente

distintas, classificação e regressão, respectivamente, essas duas categorias são apresentadas em tabelas separadas ao longo desta seção.

Esses números são retomados e discutidos qualitativamente para cada ferramenta na seção de Discussão, a seguir, que também detalha as razões pelas quais NMRQNet, nmrformer e Bayesil não puderam ser avaliadas quantitativamente.

## 4.2 Discussão

Tendo estabelecido o panorama quantitativo na seção anterior, a discussão a seguir interpreta esses resultados à luz de aspectos que as tabelas e figuras, por si só, não capturam — arquitetura de cada ferramenta, formato de entrada aceito, modo de operação e viabilidade prática de uso —, organizada em uma subseção por ferramenta avaliada.

### 4.2.1 ASICS

ASICS é um software de código aberto escrito em R (Lefort et al., 2019; Tardivel et al., 2017) que requer configuração e execução local. A ferramenta aceita nativamente arquivos no formato Bruker (`.fid`). Para os espectros adquiridos em equipamento Agilent/Varian, como esses possuíam uma estrutura de pastas diferente, tentou-se a conversão para o formato Bruker por meio da biblioteca Python `nmrglue`, (Helmus; Jaroniec, 2013) mas essa conversão resultou em perda de metadados essenciais para o processamento. A alternativa foi utilizar a segunda via de entrada disponibilizada pelo ASICS, em formato `.csv`/`.txt`, que funcionou para espectros de ambos os fabricantes após conversão.

Os dois modos, contudo, não são equivalentes em desempenho. O modo csv processou consideravelmente mais espectros pois esse aceitava espectros de ambas fornecedoras (Agilent, soro e Bruker urina, resultando em 11600 observações metabólito-espectro) que o modo fid (restrito a urina, Bruker, 2877 observações), e teve melhor detectabilidade (recall de 0,62 contra 0,27), a um custo de precisão ligeiramente menor (0,38 contra 0,62). Em termos de acurácia quantitativa, a correlação de Pearson é praticamente idêntica entre os dois modos (≈0,80), mas o MBE e o MSE do modo csv são uma a duas ordens de magnitude maiores, sugerindo que, ou o processo de conversão de formato introduz erro sistemático na escala de concentração sem descaracterizar a relação linear entre valores, ou o algoritmo de cálculo entre métodos é diferente. Entre os metabólitos individuais, ASICS é a ferramenta com os casos mais claros de "boa correlação, má quantificação": *Succinic acid* e *beta-Alanine* têm Pearson r acima de 0,7, porém MAPE acima de 2000%, um padrão consistente com erro de calibração/escala e não de ruído.

### 4.2.2 MagMet

MagMet (Lee et al., 2023; Rout et al., 2023) é uma plataforma web que processa diretamente um arquivo `.zip` contendo os FIDs de um experimento, executando de forma automática etapas de pré-processamento como transformada de Fourier, correção de fase e correção de linha de base. Na prática, apresentou dificuldade severa com arquivos no formato Bruker, não conseguindo processá-los; funcionou apenas com os espectros Agilent/Varian (soro), o que já limita sua aplicabilidade a metade do conjunto de dados deste estudo.

Entre as quatro condições quantificáveis, MagMet tem a pior detectabilidade global (recall de 18,0%, razão reportado/GS de apenas 22,5%) e a correlação de Pearson mais fraca (0,058, no limiar da significância estatística, p = 0,049). Por outro lado, é a ferramenta com a segunda maior precisão do grupo (0,80, atrás apenas de nmRanalysis, com 0,90) e o menor recall (0,18), um perfil de "poucas identificações, mas majoritariamente corretas" (baixa taxa de falso positivo, alta taxa de falso negativo). Notavelmente, o Pearson r médio calculado espectro a espectro é 0,65 (Tabela 3) — quase uma ordem de grandeza acima do 0,058 agregado, indicando que o algoritmo ordena razoavelmente bem os metabólitos dentro de cada amostra, mas a escala de calibração varia de espectro para espectro o suficiente para destruir a correlação quando os dados são agrupados. A Tabela 6, já apresentada na seção de Resultados, reforça a fragilidade estatística desses resultados: a maioria dos "melhores" casos tem apenas 1 a 3 observações, não sendo estatisticamente representativa; o único metabólito com amostragem robusta (N=126, *L-Aspartic acid*) está entre os piores (MAPE de 6790%). Apesar do desempenho fraco, MagMet é, na experiência de uso, a ferramenta mais simples de operar entre as avaliadas.

### 4.2.3 nmRanalysis

A publicação original do nmRanalysis (Flores et al., 2025) descreve a disponibilidade de um modelo de aprendizado de máquina para perfilamento, ao utilizar a plataforma, contudo, verificou-se que esse modelo não estava disponível, restando apenas o método heurístico/estatístico padrão da ferramenta.

Na ferramenta nmRanalysis, diferente das outras, nas quais os metabólitos eram identificados automaticamente pelos algoritmos, é necessário sugerir uma lista com os metabólitos que o operador quer analisar na amostra, ou seja, é uma análise direcionada. A correlação de Pearson (0,077) é a mais próxima de zero entre todas as ferramentas avaliadas, e o MAPE médio (11186%) é o maior do grupo, chegando a mais de 165000% no metabólito com maior erro (*Dimethylglycine*) e superando 70000% também em *Choline*. Mesmo os "melhores" casos por MAPE (*Dimethylamine*, *cis-Aconitic acid*, *Hippuric acid*) raramente ultrapassam Pearson r de 0,6. Em conjunto, os dados sugerem que o método disponível na plataforma não é competente em estimar a concentração de metabólitos de forma confiável, reforçando a suspeita de que o desempenho quantitativo divulgado na literatura da ferramenta dependa do modelo de aprendizado de máquina que não pôde ser avaliado neste estudo, pois esse não estava disponível.

### 4.2.4 NMRQNet

Não foi possível utilizar a ferramenta (Wang et al., 2023): os pesos do modelo de aprendizado de máquina necessários para inferência não foram disponibilizados publicamente pelos autores, inviabilizando qualquer teste, mesmo qualitativo. Não se obteve resposta ao entrar em contato com os desenvolvedores atrás dos pesos treinados.

### 4.2.5 nmrformer

nmrformer (Zhou et al., 2025) é um modelo baseado na arquitetura transformer, voltado à identificação, porém não à quantificação de metabólitos em espectros de RMN $^{1}$H. Como o escopo deste estudo é justamente avaliar identificação e quantificação frente ao padrão ouro, a ferramenta foi excluída da análise comparativa por incompatibilidade de tarefa, não por falha técnica. Trata-se, ainda assim, de uma arquitetura promissora: em princípio pode ser adaptada ou re-treinada para a tarefa de quantificação, o que a torna um candidato interessante para trabalhos futuros.

### 4.2.6 Bayesil

Bayesil (Ravanbakhsh et al., 2015) é o modelo predecessor do MagMet. No momento da avaliação, a plataforma pública da ferramenta estava desativada/obsoleta, impossibilitando qualquer teste.

## 4.3 Conclusão

A avaliação comparativa indica que nenhuma das ferramentas de perfilamento automatizado ou semiautomatizado testadas neste estudo está, no estágio atual, pronta para substituir a análise manual de um espectroscopista especialista. Das seis ferramentas selecionadas, metade (NMRQNet, nmrformer, Bayesil) sequer pôde ser avaliada quantitativamente o que já é, por si, um indicativo da maturidade desigual desse ecossistema de software.

Entre as três ferramentas que puderam ser comparadas ao padrão ouro (ASICS, MagMet, nmRanalysis), observa-se um compromisso aparente entre detectabilidade e acurácia quantitativa, com causas distintas em cada caso. ASICS combina a melhor correlação linear do grupo com um erro sistemático de escala considerável, sobretudo no modo csv, associado à conversão de formato exigida para os espectros Agilent/Varian. MagMet é a segunda ferramenta mais precisa em suas identificações, atrás apenas de nmRanalysis, mas processa o menor número de metabólitos do grupo e está limitada a um único fabricante de equipamento, o que restringe sua aplicabilidade prática. nmRanalysis apresenta a melhor recall, mas a pior acurácia quantitativa; essa vantagem em detectabilidade deve ser lida com ressalva, pois a ferramenta foi avaliada em modo de análise direcionada, na qual o operador fornece de antemão a lista de metabólitos a buscar, diferente do modo automático de ASICS e MagMet, o que tende a inflar sua recall frente às demais. Em nenhum dos três casos o MAPE médio ficou abaixo de 100%, e valores acima de 1000% foram a regra, não a exceção, o que aponta para um problema mais profundo do que ruído aleatório: erros sistemáticos de calibração/escala, coexistindo com correlações de Pearson relativamente altas no caso do ASICS.

A compatibilidade de formato de arquivo entre fabricantes (Bruker vs. Agilent/Varian) mostrou-se, na prática, uma barreira tão relevante quanto a acurácia do algoritmo em si: duas das três ferramentas quantificáveis só processam nativamente um dos dois fabricantes, obrigando a conversões de formato que, no caso do ASICS, mensuravelmente pioraram o MBE e o MSE dos resultados. Isso sugere que parte do gargalo de adoção dessas ferramentas em laboratórios multi-instrumento é de engenharia/interoperabilidade, não apenas de algoritmo estatístico.

Por fim, os resultados são compatíveis com a leitura de que etapas críticas do pré-processamento automatizado, sobretudo correção de fase e de linha de base, ainda carecem de algoritmos robustos o suficiente para dispensar a supervisão humana, e de que a promessa das abordagens baseadas em aprendizado de máquina (como a arquitetura transformer do nmrformer) permanece, neste momento, mais um caminho de pesquisa futura do que uma solução pronta para produção: a escassez de modelos treinados e disponíveis publicamente impediu, neste próprio estudo, uma avaliação justa dessa classe de método.

## 5 Referências Bibliográficas


[1] P. F. Cobra, “Aplicações de ressonância magnética nuclear em estudos metabolômicos de processos biológicos,” Tese de Doutorado, 2016.

[2] M. Rout, M. Lipfert, B. L. Lee, M. Berjanskii, and others, “MagMet: A fully automated web server for targeted nuclear magnetic resonance metabolomics of plasma and serum,” *Magnetic Resonance in Chemistry*, vol. 61, no. 12, pp. 681–704, 2023, doi: 10.1002/mrc.5371.

[3] J. E. Flores *et al.*, “nmRanalysis: An Open-Source Web Application for Semi-automated NMR Metabolite Profiling,” *Analytical Chemistry*, vol. 97, pp. 7037–7046, 2025, doi: 10.1021/acs.analchem.4c05104.

[4] B. L. Lee, M. Rout, R. Mandal, and D. S. Wishart, “Automated identification and quantification of metabolites in human fecal extracts by nuclear magnetic resonance spectroscopy,” *Magnetic Resonance in Chemistry*, vol. 61, no. 12, pp. 705–717, 2023, doi: 10.1002/mrc.5372.

[5] J. Hao, W. Astle, M. De Iorio, and T. M. D. Ebbels, “BATMAN—an R package for the automated quantification of metabolites from nuclear magnetic resonance spectra using a Bayesian model,” *Bioinformatics*, vol. 28, no. 15, pp. 2088–2090, 2012, doi: 10.1093/bioinformatics/bts308.

[6] P. J. C. Tardivel *et al.*, “ASICS: an automatic method for identification and quantification of metabolites in complex 1D 1H NMR spectra,” *Metabolomics*, vol. 13, no. 109, 2017, doi: 10.1007/s11306-017-1244-5.

[7] Chenomx Inc., “Chenomx NMR Suite User Manual.” Edmonton, Canada, 2025. [Online]. Available: https://www.chenomx.com/

[8] X. Wang *et al.*, “Comparison of Two Automated Targeted Metabolomics Programs to Manual Profiling by an Experienced Spectroscopist for 1H-NMR Spectra,” *Metabolites*, vol. 12, no. 227, 2022, doi: 10.3390/metabo12030227.

[9] W. Wang, L.-H. Ma, M. Maletic-Savatic, and Z. Liu, “NMRQNet: a deep learning approach for automatic identification and quantification of metabolites using Nuclear Magnetic Resonance (NMR) in human plasma samples,” *bioRxiv*, 2023, doi: 10.1101/2023.01.01.522434.

[10] H. Johnson and A. Tipirneni-Sajja, “Towards Optimizing Neural Network-Based Quantification for NMR Metabolomics,” *Metabolites*, vol. 15, no. 249, 2025, doi: 10.3390/metabo15040249.

[11] Z. Zhou, X. Liao, X. Qiu, Y. Zhang, and D. Lin, “NMRformer: A Deep Learning Framework for Multiplet Splitting Classification in 1H NMR,” *Analytical Chemistry*, 2025, doi: 10.1021/acs.analchem.4c05632.

[12] B. BioSpin, “Deep Learning in NMR,” technical report T186209, 2021.

[13] Mestrelab Research S.L.U., “Mnova NMR Software for 1D and 2D NMR Data.” 2026. [Online]. Available: https://mestrelab.com/main-product/nmr

[14] A. Jiang, “Insights into Nuclear Magnetic Resonance Data Pre-processing: A Comprehensive Review,” *Journal of Data Science and Intelligent Systems*, 2024, doi: 10.47852/bonviewJDSIS42022556.

[15] H. Johnson and A. Tipirneni-Sajja, “Neural Networks for Conversion of Simulated NMR Spectra from Low-Field to High-Field for Quantitative Metabolomics,” *Metabolites*, vol. 14, no. 666, 2024, doi: 10.3390/metabo14120666.

[16] H. J. Muncey, R. Jones, M. De Iorio, and T. M. D. Ebbels, “MetAssimulo: Simulation of Realistic NMR Metabolic Profiles,” *BMC Bioinformatics*, vol. 11, no. 496, 2010, doi: 10.1186/1471-2105-11-496.

[17] N. Schmid, V. Ziebart, and others, “MolDeTr: A deep learning framework for the automated decomposition of complex 1H NMR spectra,” *Journal of Magnetic Resonance*, vol. 373, p. 107851, 2025, doi: 10.1016/j.jmr.2024.107851.

[18] H. De Brouwer, “Evaluation of algorithms for automated phase correction of NMR spectra,” *Journal of Magnetic Resonance*, vol. 201, no. 2, pp. 230–238, 2009, doi: 10.1016/j.jmr.2009.09.008.

[19] G. Lefort *et al.*, “ASICS: An R package for a whole analysis workflow of 1D 1H NMR spectra,” *Bioinformatics*, vol. 35, no. 21, pp. 4356–4363, 2019, doi: 10.1093/bioinformatics/btz248.

[20] S. Ravanbakhsh *et al.*, “Accurate, Fully-Automated NMR Spectral Profiling for Metabolomics,” *PLoS ONE*, vol. 10, no. 5, p. e0124219, 2015, doi: 10.1371/journal.pone.0124219.

[21] J. J. Helmus and C. P. Jaroniec, “Nmrglue: An open source Python package for the analysis of multidimensional NMR data,” *Journal of Biomolecular NMR*, vol. 55, no. 4, pp. 355–367, 2013, doi: 10.1007/s10858-013-9718-x.

## 6 Agradecimentos

Expressa-se profunda gratidão ao Dr. José Geraldo de Carvalho, meu orientador, pela inestimável paciência, dedicação e orientação contínua ao longo de todo o desenvolvimento desta pesquisa. Seu apoio foi fundamental para a concretização deste trabalho. Agradeço, igualmente, ao Dr. Maurício Sforca e sua equipe pela generosa disponibilização dos dados que subsidiaram parte essencial deste estudo. Um reconhecimento especial é devido ao Grupo EDB do Laboratório Nacional de Biociências (LNBio), por me acolherem de forma receptiva e me tratarem como parte do time, proporcionando um ótimo ambiente de trabalho, e por todo o auxílio prestado na condução da pesquisa, incluindo a disponibilização do cluster de alto desempenho HPCC Marvin. Minha sincera gratidão se estende ao Centro Nacional de Pesquisa em Energia e Materiais (CNPEM) e ao LNBio pela infraestrutura de excelência e pelos recursos que tornaram possível a execução deste projeto. O fomento financeiro concedido pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) foi indispensável e é aqui devidamente reconhecido. Por fim, reitero que quaisquer erros ou omissões presentes neste relatório são de minha exclusiva responsabilidade.

_____

Nome e Assinatura do Aluno

_____

Nome e Assinatura do Orientador